

リアルタイム手話翻訳のための Few-shot 手話認識システムの提案

Yota Taue

概要

本研究では、少数の例示で新しいサインをその場で登録できるリアルタイム手話認識システムの実現に向け、アプリケーションとして共同開発した既存システム Handy の体系的評価と改良を行う。WLASL を用いた class-disjoint な few-shot 評価基盤を構築し、分布外 (OOD) 設定で 5-way 1-shot 44.08 % のベース性能を確認した上で、計測により特定した 3 つの欠陥へ独立に対処した。第 1 に、手検出失敗への減衰フォールバックと可視性ペナルティにより最大 +8.6 ポイント (5-way 1-shot 52.71 %, 10-way 5-shot 54.65 %) を改善した。第 2 に、推論コスト $O(NK)$ に対し DBA による原型集約で約 4.6 倍の高速化を実現し、medoid 対照実験により付随する精度低下 (4~5 ポイント) が平均化ではなく単一原型化に起因することを特定した。第 3 に、hard DTW の非微分な整合選択に対し、全整合経路に勾配を流す Soft-DTW 損失を実装・バッチ化 (約 197 倍高速化) し、単位球面正規化によるスケール不変な埋め込み空間上で学習することで、学習語彙と完全に分離した評価クラスの全設定で学習前モデルを上回る転移改善 (最大 +8.9 ポイント, 10-way 5-shot: 67.1 % $\rightarrow$ 76.1 %) を達成した。さらに新規構築した連続ストリーム評価ベンチにより、孤立クリップ精度が連続入力へ転移しないこと (配備時 WER 279.8 %) を定量化し、登録録画の leave-one-out 距離分布に基づく no-match 閾値の conformal 自動較正により、手動調整なしで WER 83.1 % (手動較正比 -4.5 ポイント) を達成した。学習済みスケルトン埋め込み上の few-shot




図 1 研究の全体像。ろう者・難聴者による少数事例の手話入力を、端末上で動作する手話認識システムが字幕・テキストとしてリアルタイムに出力し、非手話話者との対話を支援する。

手話認識への DBA・Soft-DTW・conformal 較正の導入と、計測に基づく診断的改良が本研究の新規性である。

1 背景

1.1 研究目的

世界保健機関 (WHO) の推計 [1] によれば、生活に支障をきたす難聴を抱える人口は世界で 4 億 3,000 万人を超え、世界ろう連盟 (WFD) は手話を主たる伝達手段とするろう者を約 7,000 万人と推計している [2]。手話を解さない非手話話者との対話は、ろう者・難聴者にとって依然として障壁を伴う。両者の間に存在するコミュニケーションギャップを低減するには、手話を映像から認識し、音声言語へ変換するリアルタイム翻訳システムが有効である。図 1 に研究の全体像を示す。本研究は、少数の例示で新サインを登録可能とする few-shot 学習機構と端末上で動作する軽量推論を両立させたシステム Handy (筆者がアプリケーションプロジェクトとして友人と共同開発) を研究の基盤とし、(1) few-shot 性能と連続入力性能を定量化する評価基

盤の構築, (2) 計測で特定された欠陥への段階的な改良, (3) DBA と Soft-DTW という 2 つの確立手法の few-shot 手話認識への導入, を行うものである. なお, 本稿で述べる評価基盤・改良・実験はいずれも筆者によるものである.

1.2 手話の言語的特性

手話は, 視覚と空間を用いて意味を伝達する言語であり, 手の形状・動作・位置に加え, 表情や体勢などの非手指要素 (Non-Manual Signals; NMS) が文法的役割を担う [3]. 国や地域ごとに固有の体系をもち, アメリカ手話 (ASL), 日本手話 (JSL), イギリス手話 (BSL) など, 互いに異なる手話が存在する. 同一の手形であっても, 動作の速度・反復回数・空間配置によって異なる語となる場合が多く, 一対一の固定画像で語を定義することは困難である. 加えて, 「単語」概念は音声言語よりも流動的であり, 人名・地域語・固有名詞などの新語が日常的に生成されるため, 事前に辞書を凍結する設計は本質的な限界をもつ.

1.3 リアルタイム手話翻訳の課題

手話の言語的特性から, リアルタイム手話翻訳には次の 4 課題が同時に課される. 第 1 に, 人名・地域語・固有名詞などの新語が日常的に生成されるため, 辞書を凍結する設計は**語彙の動的拡大**に対応できない. 第 2 に, 連続発話には明示的な単語境界が存在せず, 認識と区切り検出を同時に行う必要がある (**境界の不明性**). 第 3 に, 同一語でも話者・文脈に依存して実行時間・速度・反復回数が変動するため, 可変長系列を整合的に照合する仕組みが要請される (**表現の多様性**). 第 4 に, 会話的用途では低遅延が必須であり, モデルは個々の端末上で動作可能な軽量性をもつ必要がある (**端末動作要件**).

4 課題を同時に満たす設計には, 可変長系列整合・再学習不要な語彙追加・軽量入力表現の三軸を統合する必要がある. 既存の手話認識手法の多くは 4 課題のうち一部のみに対応しており, 三軸を同時に達成する手法は確立されていない.

2 関連研究

2.1 単語レベル Sign Language Recognition

教師あり学習による単語レベル Sign Language Recognition (SLR) は, 深層学習の進展とともに精度を大きく向上させてきた. WLASL データセット [4] の公開を契機として, 様々なアーキテクチャによるベンチマークが報告されている. Carreira ら [5] の I3D は, 行動認識向けに開発された 3 次元畳み込みネットワークであり, SLR においても主要なベースラインを形成した. SignBERT+ [6] は, RGB 映像とハンドモデルを用いた自己教師あり事前学習の後, 下流タスクとして教師ありで Fine-tune を行う手法であり, WLASL-2000 ベンチで Top-1 55.6% を達成している. NLA-SLR [7] は, gloss 情報を補助信号として活用する自然言語支援型の SLR であり, WLASL-2000 で 61.05% を記録している. スケルトンベースの手法としては, Tunga ら [8] が MediaPipe 由来のキーポイントを ST-GCN [9] で空間モデリングし, BERT/Transformer で系列文脈を学習する手法を提案している. Duan ら [10] は, ポーズヒートマップ系列を 3 次元畳み込みで処理する PoseConv3D を提案し, 行動認識・SLR の両領域で高い精度を示している.

2.2 連続手話認識

isolated clip の単語認識に対し, 連続手話認識 (Continuous SLR; CSLR) は連続発話を入力として gloss 列を出力するタスクである. Cui ら [11] は RNN と CNN を組み合わせた段階的最適化により CSLR の枠組みを定式化し, Camgöz ら [12] は CSLR を手話言語翻訳 (SLT) へと拡張し, attention 機構を導入した. PHOENIX-2014 [13], BSL-1K [14], How2Sign [15] などの連続した手話データセットが公開されており, 連続発話の認識性能評価環境は整備されつつある. 一方, CSLR の主流手法は依然として GPU 前提の重いモデルであり, 新サインの追加に対する Few-shot 対応も限定的である.

2.3 Zero-shot および Few-shot 手話認識

未登録クラスに対する汎化を目的とした研究も近年提案されている。Bilge ら [16] は、スケルトン特徴と意味的テキスト属性を共通埋め込み空間に整合させ、学習済みクラス外への zero-shot 転移を実現した。Saad [17] は、ST-GCN エンコーダと Prototypical Networks [18] を組み合わせたエピソード学習により、少数サンプルでの ASL 認識を達成した。Bilge ら [19] は few-shot 手話認識を言語横断設定へ拡張し、複数手話言語にまたがるメタ学習ベンチマークを提案している。少数事例学習の一般的枠組みとして、Matching Networks [20], Prototypical Networks [18], Relation Networks [21] などのメトリックベース手法と、MAML [22] に代表される最適化ベース手法が知られている。本研究で採用するメトリックベースのメタ学習は、距離関数を学習対象とすることで、再学習を伴わない新クラスへの適応を可能とする点で SLR の Few-shot 化に適合する。

2.4 DTW に基づく整合・平均化と手話認識

時系列整合の古典である DTW [23] とその部分系列拡張 [24] に対し、複数系列の代表系列を整合構造を保ちながら求める DBA [25], および整合経路選択を微分可能化する Soft-DTW [26] が提案されている。手話認識への適用例として、Costanzo [27] は正規化 DBA を映像由来の生時系列に適用してサイン分類を行い、Pu ら [28] は弱教師あり連続手話認識において映像と gloss 擬似ラベルの整合制約として Soft-DTW を用いた。ただし、前者は学習済み埋め込みを介さない生特徴量への適用であり、後者は RGB 特徴の教師あり CSLR における整合補助である。学習済みスケルトン埋め込み上の few-shot 認識に対して DBA による原型集約や Soft-DTW によるメトリック学習損失を導入した研究は、調査の限り存在しない。

2.5 本研究の位置づけ

関連研究との特性比較を表 1 に示す。ベースシステム Handy は、可変長照合 (Partial DTW)・再学習不要な語彙追加 (メトリックメタ学習)・軽量入力 (MediaPipe Hands [29] ランドマーク) の 3 軸

表 1 関連研究との特性比較。○：対応，△：部分対応，×：非対応。

手法	語彙拡張	連続入力	端末動作
SignBERT+ [6]	×	×	×
NLA-SLR [7]	×	×	×
Pose+GCN+BERT [8]	×	×	×
Continuous SLT [12]	×	○	×
Zero-shot SLR [16]	△	×	×
Few-Shot Proto [17]	○	×	×
本研究	○	○	○

を統合した設計であり、連続入力・Few-shot・端末動作を同時に扱う点で既存研究と異なる立ち位置にある。本研究の貢献はこの基盤の上に成立する：(1) few-shot (class-disjoint) と連続入力の両性能を定量化する評価基盤の構築，(2) 計測で特定された手検出脆弱性への対処，(3) DBA・Soft-DTW の few-shot 手話認識への導入である。特に (3) は、前節で述べた通り既存適用例 (生時系列への DBA [27], CSLR 整合制約としての Soft-DTW [28]) と適用対象・役割が異なり、本研究の新規性の中核を成す。

3 提案手法

本章では、まずベースシステム Handy の構成を述べ (3.1–3.5 節)、次に本研究で導入した改良を述べる (3.6 節)。

3.1 システム全体構成

提案システムは前処理パイプラインと照合パイプラインから構成される。前処理では Webcam の RGB 映像を入力とし、MediaPipe Hands によりハンドランドマーク系列を抽出した後、CNN と TCN を結合した埋め込みネットワーク TCN-SignEmbedding によって時空間特徴ベクトル系列に変換する。照合では、得られたクエリ埋め込みを原型データベースと Partial DTW で比較し、30 フレームのバッファを 3 個の窓に分割した上で、各窓における最近接クラスを連結することで字幕を生成する。訓練段階では、Prototypical Networks [18] を基盤とするメトリックベースのメタ学習により、




図 2 前処理パイプライン. MediaPipe Hands でランドマークを抽出し, TCNSignEmbedding により (30, 256) 次元のクエリ埋め込みを得る.

DTW 距離関数自体を学習対象とする.

3.2 入力表現

MediaPipe Hands [29] を用いて, 30 フレームの映像から両手それぞれ 21 点のランドマーク座標 (x, y, z) を抽出し, $(30, 42, 3)$ のテンソルを得る. 30 フレームは Webcam の取得レート約 20 fps において約 1.5 秒の系列に相当し, 1 サインの典型的な持続時間を網羅する設計である. ランドマーク抽出時に片手が検出されなかった場合は, 直前フレームの対応するランドマークを再利用するフォールバック処理を 5 フレームまで適用し, それ以降は原点に減衰させる. 減衰機構により, 検出失敗の長期化に伴う偽の凍結ポーズ信号の伝播を抑制する.

3.3 埋め込みネットワーク TCNSignEmbedding

TCNSignEmbedding は, フレーム内の空間構造を抽出する空間抽出器, 全ランドマーク特徴を統合する次元削減層, および時系列方向の文脈をモデリングする時系列モデル層の 3 段から構成される. 図 2 に処理の全体像を示す.

空間抽出器は 5 段の二次元畳み込み層 (Conv2d・BatchNorm2d・ReLU) からなり, 各フレームを縦 42・横 1 の擬似画像とみなして畳み込むことで, 隣接ランドマーク間の局所的な空間相関を抽出する. 次元削減層はカーネルサイズ 1 の Conv1d により, 統合した手指特徴量を時刻ごとに独立な線形画像で 256 次元へ圧縮する. 時間方向の情報は本層では混合せず, 後段に委ねる設計である. 時系列モデル層は Dilated 1D Convolution に基づく Temporal Convolutional Network (TCN) [30, 31] であり, 残差接続をもつ 4 個の TemporalBlock を直列に接




図 3 照合パイプライン. Partial DTW でクエリ埋め込みと各クラス原型の整合距離を計算し, 10 フレーム単位の窓ごとの最近接クラスを連結して字幕を生成する.

続する. 累積受容野は 21 フレームに達し, 30 フレームの入力窓の中央部について全文脈を考慮した特徴抽出が可能である. 最終出力は $(B, 30, 256)$ の時系列埋め込みであり, 後段の照合モジュールへ供される.

3.4 照合パイプライン

原型データベースは, N クラスそれぞれについて K 録画の埋め込み系列を保持する. クエリ埋め込みは Partial DTW により各クラス原型と比較され, 30 フレームを 3 個の窓に分割した上で, 各窓における最近接クラスが字幕として連結される (図 3).

3.4.1 Partial DTW

Dynamic Time Warping (DTW) は, Sakoe and Chiba [23] により音声認識の文脈で提案された時系列整合手法であり, 速度変動を吸収する性質をもつ. Partial DTW [24] はその拡張であり, 長さ N のクエリ系列 $\mathbf{x} \in \mathbb{R}^{N \times E}$ と長さ M の原型系列 $\mathbf{y} \in \mathbb{R}^{M \times E}$ の間で, $\mathbf{y}$ の全長を $\mathbf{x}$ の任意の部分系列と整合させる動的計画法である. コスト行列 $D \in \mathbb{R}^{N \times M}$ はフレーム間ユークリッド距離 $d(x_i, y_j) = \|x_i - y_j\|_2$ を局所コストとし,

$$D[i, j] = d(x_i, y_j) + \min\{D[i-1, j-1], D[i, j-1], D[i-1, j]\} \quad (1)$$

の漸化式により更新される. 初期条件は全 i について $D[i, 0] = d(x_i, y_0)$ とし, 原型の開始点を任意のクエリ位置に許容する. 加えて, 本実装では各セル

の起点位置を補助テーブルに記録し、後段の境界補正に利用する。後方走査により $\min_{i' \geq i} D[i', M-1]$ の単調列を得ることで、フレームインデックスに対する整合距離関数の急峻な揺らぎを抑制し、後続の argmin 復号器の安定性を確保する。

Partial DTW は速度差・部分一致・反復差を吸収する性質をもち、連続した手話における可変長照合に適合する。計算量は原型 1 個あたり $O(N \cdot M \cdot E)$ であり、 $N = 30$, $M \approx 30$, $E = 256$ の典型条件では 1 比較あたり約 2×10^5 浮動小数演算で完了する。データベース全体の推論コストは登録録画数 $D = N \cdot K$ に対し線形であり、 $O(D \cdot N \cdot M \cdot E)$ となる。

3.4.2 窓分割と字幕生成

30 フレームのクエリを長さ 10 の 3 窓に分割し、各窓内で全クラス原型の整合距離が最小となるクラスを argmin により決定する。no-match クラスとして閾値 τ を導入し、整合距離が τ を上回る場合は字幕に出力しない。字幕生成器は連続する同一クラスの予測を重複除去するとともに、連続して no-match が継続した場合に内部状態をリセットする。窓分割により、1.5 秒のバッファ内で最大 3 単語の認識を可能としつつ、連続発話における単語境界の分離を実現する。

3.5 メトリックベースのメタ学習

TCNSignEmbedding は、Prototypical Networks [18] を基盤とするメトリックベースのメタ学習で訓練される。少数事例学習において、MAML [22] に代表される最適化ベースのメタ学習はモデルパラメータの初期化を最適化対象とするのに対し、本研究で採用するメトリックベースの定式化は距離関数自体を学習対象とするため、新クラスに対する再学習を伴わない点が SLR の Few-shot に適合する。

3.5.1 Slerp 補間による連続した手話の合成

isolated clip と連続入力の分布ギャップを訓練段階で吸収するため、入力クラスの録画を球面線形補間 (Slerp) [32] により接続し、連続した手話を模倣した合成系列を生成する。Slerp によりクリップ間のランドマーク座標が滑らかに遷移するため、急峻

な切り替えに起因する人工的アーティファクトが抑制される。訓練時に連続した手話を直接観測することで、推論時の連続ストリームに対する整合性を確保する。加えて、速度変動 (0.5–1.5 倍)、位置オフセット (± 0.05)、左右反転などの拡張を併用することで、話者・カメラ・実行速度の変動に対する頑健性を高める。

3.5.2 損失関数

合成系列の埋め込み系列に対し、各クラス原型との Partial DTW 距離 d_c を計算する。距離から softmax により確率分布を構成し、

$$P(c) = \frac{\exp(-d_c)}{\sum_{c'} \exp(-d_{c'})} \quad (2)$$

式 2 に基づき、正解クラス c^* に対する交差エントロピー損失

$$\mathcal{L} = -\log P(c^*) \quad (3)$$

を最小化するように埋め込みネットワークのパラメータ θ を更新する。損失最小化により、同一クラスの埋め込みが Partial DTW 距離で近接し、異クラスの埋め込みが離れるような埋め込み空間を定めるパラメータ θ が学習される。距離関数自体を学習対象とするメトリックベースの定式化により、Few-shot 認識として未登録のクラスに対しても再学習を伴わず距離関数の汎化として対応可能となる。

3.5.3 勾配伝播の構造

式 1 における min 演算は非微分であり、整合経路の選択そのものには勾配が伝播しない。現状の損失は、hard DTW で選択された経路上のフレーム間距離 $d(x_i, y_j)$ に勾配を伝播する設計であり、経路自体は固定とみなされる。埋め込みネットワークは選択された経路上の距離を縮める方向に学習する一方、より良い経路を選べるよう整合関数を整形する方向の最適化は実現されない。以上の制約は Soft-DTW を訓練損失に導入する動機となる (3.6 節)。

3.6 本研究による改良

ベースシステムの計測 (4 章) で特定された 3 つの欠陥に対し、それぞれ独立に変更を加え効果を測定した。

3.6.1 手検出失敗への対処

WLASL 録画の約 38% のフレームでは手が検出されず、検出失敗時に直前姿勢を保持し続ける従来挙動は、偽の凍結ポーズを埋め込みに混入させていた。本研究では、(a) 5 フレーム超の欠損で当該手の座標を原点へ減衰させるフォールバック (3.2 節で詳述)、(b) 両手が 8 フレーム超欠損した場合のバッファ破棄、(c) フレームごとの検出有無マスクを原型と共に保存し、照合時に可視性パターンの不一致へペナルティを課す機構、の 3 段を導入した。

3.6.2 DBA による原型集約

推論コストがクラス数 N と録画数 K の積 $O(NK)$ に比例する問題に対し、DBA (DTW Barycenter Averaging) [25] を導入する。DBA は、代表系列 (barycenter) と各録画の DTW 整合経路を求め、経路上で対応するフレーム集合の平均で代表系列を更新する反復法であり、単純平均と異なり速度・反復のずれを整合構造を保ったまま吸収する。各クラスの K 録画を 1 つの barycenter に集約することで推論コストは $O(N)$ となり、照合ロジックの変更は不要である。平均化の寄与を切り分ける対照として、クラス内の DTW 距離総和が最小の録画 1 本を選ぶ medoid 戦略も実装した。

3.6.3 Soft-DTW 損失

hard DTW の経路選択が非微分である問題 (3.5 節) に対し、 $\min$ を温度 γ の softmin で置換する Soft-DTW [26] を訓練損失として実装した。損失は

$$\text{sdtw}_\gamma(X, Y) = -\gamma \log \sum_{\pi} \exp\left(-\frac{\langle \pi, \Delta \rangle}{\gamma}\right) \quad (4)$$

で定義され、 $\gamma \rightarrow 0$ で hard DTW に収束する。全整合経路への重み付き寄与により、整合の質自体が損失に反映され、整合しやすい埋め込みの直接学習が可能となる。本実装は解析的勾配 (Cuturi–Blondel Algorithm 2) を持ち、数値勾配との一致・ $\gamma \rightarrow 0$ 収束・学習時の損失低下を検証済みである。また、埋め込み各フレームを単位球面上へ L_2 正規化し、スケール不変な距離空間で損失を定義する。距離に基づく損失には埋め込みノルムの一様な縮小

のみで損失を減少させ得る退化解が存在するが、正規化はこれを構造的に排除するとともに、no-match 閾値の距離スケールを安定させる。推論時は引き続き hard DTW を用いるため推論コストへの影響はない。なお、CSLR の整合制約として Soft-DTW を用いた Pu ら [28] と異なり、本研究はメトリック学習の損失関数そのものへの導入である。

4 評価

4.1 評価設定

評価には WLASL データセット [4] を使用する。WLASL は約 2,000 単語規模の American Sign Language 単語認識データセットであり、YouTube・教育サイトから収集された約 21,000 動画から構成される。各動画はろう者が単語を 1 つ表現する isolated clip であり、アノテーションは単語ラベルのみである。本研究では WLASL から 300 クラスを抽出し、MediaPipe Hands により前処理した 2,569 系列を利用する。このうち録画数 10 以上の 85 クラスを評価対象とし、固定シードで 45 クラス (base) と 40 クラス (novel) に分割する。評価エピソードは novel の 40 クラスのみから構成し、base クラスは将来の Fine-tune 実験のために確保する class-disjoint 設定とする。

■**孤立クリップ評価** n-way k-shot エピソードを用いる。各エピソードでは novel クラスから n クラスを抽出し、各クラスから k 個のサポート録画と 5 個のクエリ録画をサンプリングする。埋め込みモデルは WLASL を一切学習していないため、本評価は分布外 (Out-of-Distribution; OOD) 設定での転移性能測定として機能する。評価指標は Top-1 精度とし、各設定 1,000 エピソードの平均と標準偏差を報告する。

■**連続ストリーム評価** isolated clip では測定不可能な連続入力性能を定量化するため、評価ベンチを新規に構築した。novel 40 クラス全てを語彙として登録 (クラスあたり $K=5$ サポート録画) した上で、残りの録画から 8 サインを無作為抽出し、学習時と同一の Slerp 補間 (5-30 フレーム) で接続した合成連続ストリームを生成する。配備系の推論

表 2 手検出対策の段階的効果 (Top-1 精度, 単位: %)

設定	対策前	+ 減衰 (a)(b)	+ 可視性 (c)
5-way 1-shot	44.08	52.71	52.22
10-way 1-shot	32.61	39.56	39.30
10-way 5-shot	47.33	52.37	54.65

ループ (30 フレーム非重複バッファ → 埋め込み → Partial DTW 照合 → 重複除去復号) を忠実に再現し, 認識単語列と参照単語列の編集距離に基づく WER (置換 S・削除 D・挿入 I の内訳付き), および予測ラベル変化点と真の遷移中点を許容誤差 15 フレームで照合した境界適合率・再現率を報告する (100 ストリーム).

4.2 評価結果

4.2.1 ベース性能

ベースシステムの OOD 性能は表 2 の「対策前」列に示すとおりであり, 5-way 1-shot 44.08% (chance 20%), 10-way 1-shot 32.61% (chance 10%), 10-way 5-shot 47.33% であった. いずれの設定でも chance level を有意に超過し, 1-shot から 5-shot への移行で 14.7 ポイント向上したことから, 原型表現の質が認識精度を強く支配することが示唆される.

4.2.2 手検出失敗への対処の効果

表 2 に 3.6.1 節の改良の効果を示す. 減衰フォールバックを含む再前処理のみで全設定 +5.0~+8.6 ポイントの大幅改善が得られ, 前処理の頑健性がモデル以前の支配的要因であることが確認された. 可視性ペナルティは 5-shot で +2.3 ポイントの追加改善を示す一方, 1-shot では原型 1 本あたりの可視性推定が不安定なため効果を示さなかった.

4.2.3 DBA 原型集約の診断

表 3 に, 再前処理後のデータにおける原型戦略 3 種の比較を示す. DBA は per-recording 比で 4~5 ポイントの精度低下を示すが, medoid 対照との差は全設定で 0.5 ポイント未満 (95% 信頼区間内) であり, 低下の主因は平均化ではなく**単一原型化そのもの**にあることが分かる. すなわち現在の埋め込み空間は, クラス内変動 (速度・癖) を 1 本の系列

表 3 原型戦略の比較 (Top-1 精度 [%], $K=5$, 再前処理後). per-rec. は 5 本/クラス, medoid・DBA は 1 本/クラス.

設定	per-rec.	medoid	DBA
5-way 5-shot	66.55	61.82	61.34
10-way 5-shot	52.37	48.96	48.60
20-way 5-shot	42.44	38.36	38.34




図 4 原型集約による照合レイテンシの改善 (実測). per-recording は全 K 録画と照合するため推論コストが $O(NK)$ で増大するのに対し, DBA はクラスあたり 1 本の barycenter に集約することで $O(N)$ に抑え, 80 クラス時で約 4.6 倍高速化する.

で代表しきれない. 一方レイテンシは 80 クラス・ $K=5$ 時に 1 クエリあたり 108 ms から 23 ms へ約 4.6 倍改善し (図 4; barycenter 構築は 1 クラスあたり約 12 ms の 1 回限り), 4~5 ポイントの精度と引き換えに原型数 $1/K$ と実時間動作を得る実用的なトレードオフであることが示された. 残る精度ギャップの解消には埋め込み空間側の改善が必要であり, Soft-DTW 学習 (3.6.3 節) の動機となる.

4.2.4 連続ストリーム評価

図 5 に連続ストリーム評価の WER と誤り内訳を示す. 配備時設定では WER 279.8% と, 挿入誤り (I 218.6%) が氾濫する破綻状態にあり, **孤立クリップ精度 (52~55%) は連続入力へ転移しない**ことが定量的に示された. 原因は (i) 原型録画の冒頭・末尾に含まれる手非検出区間 (平均 38% のフレーム) が任意のストリーム区間と低コスト整合すること, (ii) 固定閾値 0.9 が正規化コスト分布

(0.0–0.5) に対して一度も発火しないこと、と診断された。原型の有効区間トリミング・連続 3 チャンク一致の発火条件・閾値 0.35 への較正により WER は 93.9% まで改善するが、残る誤りは置換が支配的であり、整合器・埋め込み空間自体の改善が必要である。DBA 原型は同一較正下で WER 87.6% と per-recording を上回り、かつ 1 バッファあたり 16 ms (6.3 倍高速) で動作するが、誤り内訳は削除支配 (D 66.9%) へ反転しており、閾値較正が原型戦略に依存することを示す。medoid 原型も同様の傾向を示した (WER 89.4%)。なお境界適合率・再現率の F1 は全構成で 0.15–0.37 にとどまり、単語境界の同定自体が未解決の課題として残る。

この戦略依存性に対し、登録録画そのものから閾値を自動推定する conformal 較正を導入した。各登録録画を 1 本ずつ除外し、残りから当該戦略で構築した自クラス原型に対する正規化整合コスト (leave-one-out 本人スコア) を計測し、その分位点を no-match 閾値とする。分布仮定なしに真のサインの受理率を制御でき、閾値は原型戦略・語彙・ユーザーごとに自動適応する (図 6)。中央値 ($q=0.5$) による閾値は per-recording で 0.343 と手動探索値 (0.35) をほぼ再現して WER 93.5% (手動 93.9%) を与え、DBA では 0.448 へ自動適応して WER を 87.6% から **83.1%** へ改善するとともに、削除支配だった誤り内訳の偏りを解消した (S 44.0 / D 38.8 / I 0.4%)。

4.2.5 Soft-DTW 学習の転移評価

■**学習設定** Soft-DTW の動的計画部をエピソード × 原型の全ペアで一括計算するバッチ化カーネルを実装し、1 エポックの学習時間を 51 分から約 67 秒へ短縮 (約 197 倍) した。学習は、学習語彙から評価クラスを完全除外したパイプライン (240/20 クラスの class-disjoint 分割, AdamW, early stopping) で行い、埋め込みには 3.6.3 節の単位球面正規化を適用する。温度は $\gamma \in \{0.1, 0.5, 1.0, 2.0\}$ の感度解析において一貫して小さい値が優位であったため、 $\gamma=0.1$ を採用した。

■**転移評価** 転移評価は、novel 40 クラスのうち Fine-tune の学習語彙 (WLASL 上位 100 クラス)




図 5 連続ストリーム評価の WER と誤り内訳。配備時設定は挿入誤り (I) の氾濫により WER 279.8% で破綻する。復号器の較正で挿入は抑制されるが、原型戦略により支配的な誤り種別が置換 (per-recording) と削除 (DBA) の間で反転する。conformal 自動較正は DBA において WER 83.1% と内訳の均衡を同時に達成する。




図 6 conformal 較正における leave-one-out 本人スコア分布。per-recording と DBA では本人スコア分布が異なるため、中央値による自動閾値は戦略ごとに 0.343 / 0.448 へ自動適応する。per-recording では手動探索値 0.35 をほぼ再現する一方、DBA ではより大きな閾値が要請されることが分布から読み取れる。

と重複しない 11 クラス (clean11) で行い、学習・評価語彙の完全分離を保証する。図 7 に示すとおり、修正後の Soft-DTW 学習 (30 エポック) は全設定で学習前モデルを上回り、10-way 5-shot で +8.9 ポイント、1-shot でも +4.2~5.2 ポイントの転移改善を達成した。改善は novel 40 全体でも一貫する (5-way 1-shot 52.71% → 56.81%)。L2 正規化を評価時のみ適用した統制条件 (baseline + L2) は




図7 clean11 における Soft-DTW 学習の転移改善. 学習語彙と完全に分離した評価クラス的全設定で学習前モデルを上回り, 10-way 5-shot では 67.1% から 76.0% へ改善する.

学習前モデルと同等 (± 0.5 ポイント) であり, 改善が正規化自体ではなく学習に由来することを確認した. 転移性能は学習長に対して 30 エポックまで単調に改善し続けた一方, class-disjoint 検証精度の最良時点 (8 エポック) とは一致せず, チェックポイント選択プロトコルには改善の余地がある.

4.3 現時点の制約

第 1 に, WLASL は話者横断データであり, サポート・クエリ・ストリームが異なる話者に由来する. 実利用 (本人が登録し本人が手話をする) より厳しい条件であり, 報告値は実利用時の下限に相当すると考えられる. 第 2 に, 連続ストリームは isolated clip の Slerp 合成であり, 実際の連続した手話に存在する調音結合 (coarticulation) は再現されない. 第 3 に, clean11 は 11 クラス構成のため 10-way 評価はほぼ同一のクラス集合の反復となり, エピソード信頼区間はクラスレベルの不確実性を過小評価する. 第 4 に, 学習実験は単一シードでの実施であり, 複数シードでの再現は今後の課題である.

5 今後の展望

5.1 学習信号と埋め込み空間の改善

Soft-DTW 学習により全設定での転移改善を確認した (4.2.5 節) が, 転移性能は学習長に対して単調に改善し続けており収束点は未確定である. 今

後は学習スケジュールの延長と, 転移性能と相関するチェックポイント選択プロトコル (複数シード・検証エピソードの固定) の確立を進める. また medoid 対照実験が示した単一原型化のコストに対しては, Soft-DTW で学習された整合容易な埋め込み空間上では barycenter がクラス内変動をより良く代表できる可能性があり, Soft-DTW barycenter [26] の導入を含め, 原型集約と埋め込み学習の統合的な改善を検討する.

5.2 連続復号器の改良

no-match 閾値の自動較正は conformal 較正として実現し, 手動調整を上回る WER を確認した (4 章). 今後は, (1) クラス内変動の差を扱うクラス別 (Mondrian) 閾値と, 本人・他人スコアの両側を用いた較正への拡張, (2) チャンク単位 argmin に代わる時間平滑化・セグメンテーションを考慮した復号器, (3) 残存する置換誤りの主因である埋め込みの判別性向上との統合, を検討する.

5.3 非手指要素と可視性のランドマーク拡張

手のランドマーク 42 点のみでは, 表情や体勢などの非手指要素を表現できない. MediaPipe Face Mesh および Pose の統合により口形・眉位置・体勢を含む拡張ランドマーク集合を入力とするとともに, 検出失敗を明示する可視性マスクを第 4 チャンネルとして埋め込みネットワークに与える設計を検討する. 拡張後も RGB の直接処理は回避するため, 端末動作要件は維持される.

5.4 ユーザー適応の評価

本システム本来のユースケースは個人ごとの新サイン登録であり, 登録する人と手話を行う人が同一人物となる. WLASL の話者横断評価はこれより厳しい条件であるため, 被験者ごとに登録・評価セットを分割した実験設計を構築し, 登録録画数 K と精度の関係, および実利用条件での性能を定量化する.

6 結論

本研究では, 共同開発システム Handy を対象に, few-shot (class-disjoint) と連続入力の両性能を測る評価基盤を構築し, 計測に基づく診断的改良を

行った。得られた知見は次の3点に整理される。

第1に、前処理の頑健性がモデル以前の支配的要因であった。手検出失敗への対処のみでモデルを変更せず Top-1 精度が最大 +8.6 ポイント改善したことは、few-shot 性能の律速がアーキテクチャではなく入力表現の欠損処理にあったことを示す。第2に、孤立クリップの精度は連続入力へ転移しない。新規に構築した連続ストリーム評価ベンチにより、配備時の破綻が認識器ではなく復号器の閾値較正に起因することを切り分け、登録録画の leave-one-out 距離分布に基づく conformal 自動較正が、手動調整を上回る WER を原型戦略に依存せず与えることを示した。第3に、DBA による原型集約に伴う精度低下は、平均化ではなく単一原型化そのものに起因する。medoid 対照実験によりこれを分離し、残る精度ギャップが埋め込み空間側の課題であることを特定した。この診断に対し、全整合経路に勾配を流す Soft-DTW 損失による学習は、学習語彙と完全に分離した評価クラスの全設定で学習前モデルを上回る転移改善を示した。

本研究の新規性は、学習済みスケルトン埋め込み上の few-shot 手話認識への DBA 原型集約・Soft-DTW メトリック学習損失・conformal 閾値較正の導入、および計測に基づく診断的改良にある。今後は、学習スケジュールの更なる延長、クラス別 (Mondrian) 閾値への較正拡張、非手指要素・可視性チャンネルへの入力拡張、ユーザー適応評価へと段階的に発展させ、実用的なリアルタイム手話翻訳ツールの実現を目指す。

参考文献

- [1] World report on hearing. Technical report, World Health Organization, 2021.
- [2] World Federation of the Deaf. Our work. <https://wfdeaf.org/our-work/>, 2024. Accessed 2026-06.
- [3] William C. Stokoe. Sign language structure: An outline of the visual communication systems of the american deaf. *Studies in Linguistics: Occasional Papers*, (8), 1960.
- [4] Dongxu Li, Cristian Rodriguez, Xin Yu, and Hongdong Li. Word-level deep sign language recognition from video: A new large-scale dataset and methods comparison. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2020.
- [5] Joao Carreira and Andrew Zisserman. Quo vadis, action recognition? a new model and the kinetics dataset. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [6] Hezhen Hu, Weichao Zhao, Wengang Zhou, and Houqiang Li. Signbert+: Hand-model-aware self-supervised pre-training for sign language understanding. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023.
- [7] Ronglai Zuo, Fangyun Wei, and Brian Mak. Natural language-assisted sign language recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023.
- [8] Anirudh Tunga, Sai Vidyaranya Nuthalapati, and Juan Wachs. Pose-based sign language recognition using gcn and bert. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision Workshops*, 2021.
- [9] Sijie Yan, Yuanjun Xiong, and Dahua Lin. Spatial temporal graph convolutional networks for skeleton-based action recognition. In *AAAI Conference on Artificial Intelligence*, 2018.
- [10] Haodong Duan, Yue Zhao, Kai Chen, Dahua Lin, and Bo Dai. Revisiting skeleton-based action recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.
- [11] Runpeng Cui, Hu Liu, and Changshui

- Zhang. Recurrent convolutional neural networks for continuous sign language recognition by staged optimization. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [12] Necati Cihan Camgöz, Simon Hadfield, Oscar Koller, Hermann Ney, and Richard Bowden. Neural sign language translation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018.
- [13] Jens Forster, Christoph Schmidt, Oscar Koller, Martin Bellgardt, and Hermann Ney. Extensions of the sign language recognition and translation corpus rwth-phoenix-weather. In *Proceedings of the International Conference on Language Resources and Evaluation (LREC)*, 2014.
- [14] Samuel Albanie, Gül Varol, Liliane Momeni, Triantafyllos Afouras, Joon Son Chung, Neil Fox, and Andrew Zisserman. BSL-1K: Scaling up co-articulated sign language recognition using mouthing cues. In *European Conference on Computer Vision*, 2020.
- [15] Amanda Duarte, Shruti Palaskar, Lucas Ventura, Deepti Ghadiyaram, Kenneth DeHaan, Florian Metze, Jordi Torres, and Xavier Giro-i Nieto. How2Sign: A large-scale multimodal dataset for continuous american sign language. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.
- [16] Yunus Can Bilge, Ramazan Gokberk Cinbis, and Nazli Ikizler-Cinbis. Towards zero-shot sign language recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022.
- [17] M. M. Saad. Data-efficient american sign language recognition via few-shot prototypical networks. *arXiv preprint*, 2025.
- [18] Jake Snell, Kevin Swersky, and Richard Zemel. Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, 2017.
- [19] Yunus Can Bilge, Nazli Ikizler-Cinbis, and Ramazan Gokberk Cinbis. Cross-lingual few-shot sign language recognition. *Pattern Recognition*, 151:110374, 2024.
- [20] Oriol Vinyals, Charles Blundell, Timothy Lillicrap, Koray Kavukcuoglu, and Daan Wierstra. Matching networks for one shot learning. In *Advances in Neural Information Processing Systems*, 2016.
- [21] Flood Sung, Yongxin Yang, Li Zhang, Tao Xiang, Philip H. S. Torr, and Timothy M. Hospedales. Learning to compare: Relation network for few-shot learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018.
- [22] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *International Conference on Machine Learning*, 2017.
- [23] Hiroaki Sakoe and Seibi Chiba. Dynamic programming algorithm optimization for spoken word recognition. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 26(1):43–49, 1978.
- [24] Meinard Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Springer, 1 edition, 2015.
- [25] François Petitjean, Alain Ketterlin, and Pierre Gançarski. A global averaging method for dynamic time warping, with applications to clustering. *Pattern Recognition*, 44(3):678–693, 2011.
- [26] Marco Cuturi and Mathieu Blondel. Soft-DTW: a differentiable loss function for time-series. In *International Conference on Ma-*

- chine Learning*, pages 894–903, 2017.
- [27] John A. W. B. Costanzo. Regularization of dynamic time warping barycenter averaging, with applications in sign classification. Master’s thesis, Rochester Institute of Technology, 2013.
 - [28] Junfu Pu, Wengang Zhou, and Houqiang Li. Iterative alignment network for continuous sign language recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019.
 - [29] Fan Zhang, Valentin Bazarevsky, Andrey Vakunov, Andrei Tkachenka, George Sung, Chuo-Ling Chang, and Matthias Grundmann. Mediapipe hands: On-device real-time hand tracking. *arXiv preprint arXiv:2006.10214*, 2020.
 - [30] Shaojie Bai, J. Zico Kolter, and Vladlen Koltun. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*, 2018.
 - [31] Colin Lea, Michael D. Flynn, René Vidal, Austin Reiter, and Gregory D. Hager. Temporal convolutional networks for action segmentation and detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
 - [32] Ken Shoemake. Animating rotation with quaternion curves. In *Proceedings of the 12th Annual Conference on Computer Graphics and Interactive Techniques (SIGGRAPH)*, pages 245–254, 1985.