

リアルタイム手話翻訳のための Few-shot 手話認識システムの提案

既存の手話認識研究の多くは教師あり学習で語彙が固定され、新語の追加に再学習を要し、isolated clip と GPU 推論を前提とするため、連続した手話を端末上でリアルタイムに認識することは難しい。そこで本研究は、MediaPipe [1] ランドマークを CNN+TCN で時空間埋め込みに変換し、速度差・部分一致を吸収する Partial DTW [2] と Prototypical Networks [3] ベースのメタ学習を組み合わせることで、再学習不要な語彙追加・連続入力への認識・軽量の端末動作を同時に満たす Few-shot 手話認識システムを提案する。WLASL [4] を用いた class-disjoint な few-shot 評価基盤と連続ストリーム評価ベンチを構築し、手検出フォールバック、DBA [5] 原型集約による照合の高速化、棄却閾値を自動推定する conformal 較正、Soft-DTW [6] による埋め込み学習の4つの改良を行い、それぞれの効果を定量的に示す。

背景

手話は視覚と空間で意味を伝える言語であり、世界に約7,000万人のろう者・難聴者がいるとされる。
音声言語と異なり、手話翻訳には固有の難しさがある。


手話の特性	課題
人名・地域語・固有名詞が日常的に生成される → 辞書を凍結できない	語彙の動的拡大
話者の単語ごとの区切りがない → 境界検出と認識を同時に行う必要	連続発話のセグメント境界不明
同一語でも実行時間にぶれがある。反復・速度も話者・文脈依存	速度・反復の多様性
利便性・低遅延（会話）のためモデルが個々の端末に乗りなければならない	端末動作要件

先行研究 & 目標

※先行研究はいずれもGPU推論前提のため、軽量・低遅延の端末動作は不可




手話翻訳における先行研究で4つの課題を同時に満たすものは存在しない
→ 「同クラスの埋め込みはDTWで近く・異クラスは遠くなる空間θ」
を学習する下のメトリックベースのメタ学習の
ベースシステムを以前にプロジェクトとして友人と共同開発した




- ① 手が検出できないフレーム（全体の38%）で直前の姿勢を保持し続けるため、**実在しない静止ポーズが埋め込みを汚染する**
- ② 原型DB全登録録画との総当たり DTW のため、**照合コストが語彙数に比例する**（80クラスで108ms/クエリ）
- ③ 「該当なし」判定閾値が実際の距離分布とズレて機能せず、**非手話時も字幕が出続ける**。最適値は原型戦略ごとに異なり、手動調整は破綻する
- ④ 学習時のhard DTW は最良の整合経路にしか勾配を流さず、**埋め込み空間の改善が制限される**

提案手法（改善）


- ① 5フレームで原点へ減衰するフォールバックと、両手長期欠損時のバッファ破棄を導入
- ② DBA で K本の録画をタイミングを揃えて平均した代表系列1本に集約（照合対象を1/Kに）



- ③ 登録録画の leave-one-out スコア分布から閾値を自動推定する conformal calibrationを導入



- ④ 全経路に勾配を流す Soft-DTW 損失, 単位球面正規化によるスケール不変性埋め込みを fine-tune



実験 & 結果

【データセット】

WLASL [4] - 約21,000本のASL（アメリカ手話）動画からなる、約2,000単語規模の孤立手話データセット、300クラスを MediaPipe で骨格系列化（2,569系列）

【学習・評価方法】

評価: 録画数10以上の85クラスを base 45 / novel 40 に分割し、novelのみで n-way k-shot を1,000エピソード平均 (OOD)

学習: novel 40 を完全除外した 240/20 クラスで fine-tune し、転移は学習語彙と重複しない 11クラスで測定

連続評価: novel のクリップを Slerp 補間で接続した合成ストリーム 100本 × 8手話、WER で評価

改良	評価指標	改良前	改良後	効果
① 手検出フォールバック	Top-1 精度 (5-way 1-shot)	44.1 %	52.7 %	+8.6
② DBA 原型集約	照合時間 (80クラス)	108 ms	23 ms	×4.6
③ conformal 自動較正	連続入力 WER (DBA)	87.6 %	83.1 %	-4.5
④ Soft-DTW + 正規化学習	Top-1 精度 (10-way 5-shot)	67.1 %	76.1 %	+8.9

[1] F. Zhang et al., "MediaPipe Hands: On-device Real-time Hand Tracking," arXiv:2006.10214, 2020.

[2] M. Müller, Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications, Springer, 2015.

[3] J. Snell, K. Swersky, and R. Zemel, "Prototypical Networks for Few-shot Learning," Advances in Neural Information Processing Systems (NeurIPS), 2017.

[4] D. Li, C. Rodriguez, X. Yu, and H. Li, "Word-level Deep Sign Language Recognition from Video: A New Large-scale Dataset and Methods Comparison," IEEE/CVF Winter Conference on Applications of Computer Vision (WACV), pp. 1459-1469, 2020.

[5] F. Petitjean, A. Ketterlin, and P. Gangarsi, "A Global Averaging Method for Dynamic Time Warping, with Applications to Clustering," Pattern Recognition, vol. 44, no. 3, pp. 678-693, 2011.

[6] M. Cuturi and M. Blondel, "Soft-DTW: A Differentiable Loss Function for Time-Series," International Conference on Machine Learning (ICML), PMLR 70, pp. 894-903, 2017.